

Seq2seq 구조의 어텐션 메커니즘 변형을 통한 챗봇 응답의 편향성 완화 효과 분석

2026년 3월 19일

Abstract

본 연구는 신경망 기반 대화 생성 모델이 학습 데이터셋 내에 내재된 성별, 인종, 직업군에 대한 사회적 편향(Social Bias)을 무분별하게 학습하고, 이를 추론 과정에서 증폭시키는 구조적 메커니즘을 심층 분석한다. 기존의 Sequence-to-Sequence(Seq2seq) 및 표준 어텐션 메커니즘은 단어 간의 결합 확률과 통계적 빈도에 전적으로 의존하기 때문에, 특정 문맥에서 편향된 토큰에 비정상적으로 높은 확률 가중치를 부여하는 한계가 있다. 본 논문은 이러한 한계를 극복하기 위해 디코딩 단계에서 편향 유발 토큰의 선택 확률을 수학적으로 억제하는 'Bias-Penalty Attention (BPA)' 아키텍처를 제안한다. 실험 결과, 제안된 모델은 대화의 자연스러움을 의미하는 BLEU 점수를 27.85 수준으로 유지하면서도, WEAT score에서 기존 대비 62.5%의 감소를 달성하였다. 본 연구는 인공지능 윤리를 모델의 연산 계층에서 직접 제어할 수 있는 실무적 방법론을 제시한다.

Contents

1	Introduction	3
1.1	연구의 배경 및 인공지능 윤리의 사회적 대두	3
1.2	기존 편향 완화 기법의 비판적 고찰	3
1.3	본 연구의 목적 및 기술적 기여	3
2	Background and Related Works	4
2.1	Seq2seq 아키텍처와 정보 병목 현상(Information Bottleneck)	4
2.2	Standard Attention Mechanism의 수식적 편향 증폭 분석	4
3	Methodology: Bias-Penalty Attention	5
3.1	BPA의 심층적 설계 및 정보 이론적 배경	5
3.2	수정된 에너지 점수 함수 및 하이퍼파라미터 최적화	5
3.3	추론 프로세스 알고리즘 설계	5
4	Experimental Results	6
4.1	Dataset 구성 및 통계적 분석	6
4.2	학습 안정성 분석: Loss 및 Accuracy의 수렴 양상	6
4.3	Quantitative Metrics: 상세 지표 비교	6
4.4	Attention Map Visualization 분석	6
5	Discussion and Case Study	7
5.1	패널티 계수(β)에 대한 민감도 및 정보 이론적 임계값 분석	7
5.2	정성적 사례 분석: 실제 응답 대조 및 문맥 유지력 검증	8
5.3	심층 분석: 모델의 인지적 저항과 대안 탐색 경로	9
5.4	오차 분석 및 예외 상황(Error Analysis)	9
6	Conclusion	9
6.1	연구 성과 및 학술적 요약	9
6.2	사회적 기여도 및 실무적 기대효과	10
6.3	연구의 한계점 및 향후 연구 방향	10

1 Introduction

1.1 연구의 배경 및 인공지능 윤리의 사회적 대두

최근 초거대 언어 모델(LLM)과 딥러닝 기술의 비약적인 발전은 인간과 기계 사이의 자연스러운 상호작용을 가능케 하였으나, 기술적 성취 이면에 가려진 '알고리즘적 편향성' 문제는 현대 인공지능 연구의 가장 시급한 과제로 부상하였다. 특히 대규모 웹 데이터셋을 기반으로 학습된 대화 모델은 인류가 수 세기 동안 쌓아온 고정관념과 차별적 언어 습관을 여과 없이 학습한다. 이러한 모델이 산업 현장의 안전 가이드라인 제공이나 공공 서비스용 상담 챗봇으로 활용될 경우, 특정 집단에 대한 혐오 표현이나 왜곡된 직업관을 출력함으로써 심각한 사회적 갈등을 야기할 수 있다.

1.2 기존 편향 완화 기법의 비판적 고찰

과거의 연구들은 주로 학습 데이터셋 자체를 정제(Data Filtering)하거나, 워드 임베딩 공간의 사후 보정(Post-processing)에 집중해왔다. 그러나 데이터 정제 방식은 언어의 다양성을 해치고 학습 말뭉치의 크기를 감소시켜 모델의 전반적인 언어 생성 성능(Perplexity)을 저하시키는 부작용을 초래한다. 또한, 임베딩 보정 방식은 단어 간의 정적인 기하학적 거리는 조정할 수 있으나, 문장 생성 과정에서 매 순간 변하는 동적인 문맥(Dynamic Context) 정보를 반영하지 못한다는 구조적 한계를 노출하였다.

1.3 본 연구의 목적 및 기술적 기여

본 연구는 모델이 응답 문장을 구성하는 '결정적 추론 순간'인 어텐션 메커니즘(Attention Mechanism)에 직접 개입한다. 제안하는 'BPA(Bias-Penalty Attention)' 구조는 데이터의 손실 없이 알고리즘의 수식적 변형만으로 편향성을 정밀하게 타격하며, 이를 통해 성능과 윤리라는 두 가지 목표 사이의 최적의 균형점(Pareto Frontier)을 도출한다.

2 Background and Related Works

2.1 Seq2seq 아키텍처와 정보 병목 현상(Information Bottleneck)

Sequence-to-Sequence(Seq2seq) 모델은 인코더가 입력 시퀀스를 고정된 크기의 컨텍스트 벡터로 압축하고, 디코더가 이를 다시 가변 길이의 시퀀스로 복원하는 구조이다. 조정현(Cho et al., 2014) 등의 연구에서 지적되었듯이, 긴 문장의 정보를 단일한 벡터에 함축하는 과정에서 발생하는 정보의 병목 현상은 모델로 하여금 세밀한 인과관계보다는 학습 데이터셋에서 가장 빈번하게 등장했던 '지름길 확률(Shortcut Probability)'에 의존하게 만든다.

2.2 Standard Attention Mechanism의 수식적 편향 증폭 분석

Bahdanau et al. (2015)이 제안한 어텐션 메커니즘은 디코더의 특정 상태 s_{i-1} 와 인코더의 모든 은닉 상태 h_j 사이의 상관관계를 점수화한다.

$$e_{ij} = v_a^\top \tanh(W_a s_{i-1} + U_a h_j) \quad (1)$$

이 점수는 소프트맥스(Softmax) 함수를 통해 확률 분포 α_{ij} 로 변환되는데, 여기서 소프트맥스의 수학적 특성에 주목해야 한다.

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^{T_x} \exp(e_{ik})} \quad (2)$$

지수 함수(exp)는 입력값 간의 미세한 차이를 극단적으로 확대하는 성질을 가진다. 따라서 데이터 셋 내에서 특정 단어 쌍(예: '프로그래머'와 '남성')의 공출현 빈도가 통계적으로 조금이라도 높게 설정되어 있다면, 어텐션 가중치는 이 차이를 수십 배로 증폭시켜 편향된 단어 선택을 강제하게 된다.

3 Methodology: Bias-Penalty Attention

3.1 BPA의 심층적 설계 및 정보 이론적 배경

본 연구에서 제안하는 BPA(Bias-Penalty Attention)는 단순한 필터링이 아닌, 어텐션 분포의 엔트로피를 조절하는 기법이다. 표준 어텐션이 특정 편향 토큰에 대해 과도한 확신(Over-confidence)을 가질 때, BPA는 이를 확률론적으로 보정하여 보다 중립적인 대안적 토큰(Alternative Tokens)을 탐색하도록 유도한다.

3.2 수정된 에너지 점수 함수 및 하이퍼파라미터 최적화

수식적으로 BPA는 어텐션 에너지 e_{ij} 에 패널티 항을 삽입하여 다음과 같이 정의된다.

$$e'_{ij} = \text{Score}(s_{i-1}, h_j) - \beta \cdot \phi(w_j) \quad (3)$$

여기서 β 는 사용자가 정의하는 패널티 강도 하이퍼파라미터이며, $\phi(w_j)$ 는 후보 단어 w_j 가 사전 정의된 편향 유발 어휘 사전 V_{bias} 에 포함될 경우 1을 반환하는 지시 함수이다. 본 연구는 β 의 크기가 모델의 유창성과 윤리적 건전성 사이의 최적 임계값을 결정하는 핵심 변수임을 실험적으로 입증한다.

3.3 추론 프로세스 알고리즘 설계

제안된 BPA의 전체 추론 과정을 알고리즘 1에 상세히 기술하였다. 이 과정은 매 디코딩 스텝마다 수행되며, 연산 복잡도 증가를 최소화하기 위해 해시 맵(Hash Map) 기반의 사전 탐색 구조를 채택하였다.

4 Experimental Results

4.1 Dataset 구성 및 통계적 분석

본 연구는 Cornell Movie-Dialogs Corpus를 기반으로 한국어 혐오표현 및 편향성 데이터를 추가 구축하여 총 100,000쌍의 대화 데이터를 사용하였다. 데이터셋 내 성별 편향 단어의 비율은 약 14.2%로 확인되었으며, 이를 학습(80%), 검증(10%), 평가(10%) 셋으로 분할하였다.

4.2 학습 안정성 분석: Loss 및 Accuracy의 수렴 양상

제안 모델의 학습 안정성을 검증하기 위해 50 에포크(Epoch) 동안의 Cross-Entropy Loss 추이를 관찰하였다. 그림 1(a)는 학습 진행에 따른 손실 함수의 변화를 나타낸다.

분석 결과, BPA 모델은 초기 5,000 Step 구간에서 표준 모델 대비 약 12% 높은 손실값을 기록하였다. 이는 패널티 항이 기존의 강한 통계적 결합(Strong Priors)을 깨뜨리는 과정에서 발생하는 일시적인 불확실성 증대로 해석된다. 그러나 15,000 Step 이후 두 모델의 수렴 궤적이 일치하는 현상은, 모델이 편향된 연결 고리를 배제하고도 문맥적으로 정교한 응답을 생성하는 '대안 경로(Alternative Path)'를 성공적으로 학습했음을 시사한다.

그림 1(b)는 학습 과정에서의 Top-1 Accuracy 추이를 보여준다. BPA 모델은 최종 수렴 시점에서 표준 모델(74.2%) 대비 약 0.3% 포인트의 근소한 정확도 하락(73.9%)만을 기록하였다.

4.3 Quantitative Metrics: 상세 지표 비교

표 1은 대화 품질(BLEU), 내용 일치도(ROUGE), 그리고 핵심인 편향성(WEAT) 지표를 상세히 비교한 결과이다.

4.4 Attention Map Visualization 분석

그림 2의 어텐션 히트맵 시각화 결과는 본 연구의 핵심 가설을 뒷받침한다. 표준 모델이 직업군 토큰 생성 시 특정 성별 지표에 에너지를 집중시키는 반면, BPA 모델은 해당 시점의 패널티를 통해 가중치를 문맥 내의 형용사나 중립 명사로 분산시켜 보다 포용적인 응답을 유도하는 메커니즘을

Model	Con-figuration	BLEU-4	ROUGE-L	Acc (%)	WEAT Score ↓
Standard	RNN	24.52	22.10	68.4	0.482
Baseline					
Standard		28.14	26.35	74.2	0.395
Seq2seq + Attn					
BPA	(Ours,	28.01	26.21	74.1	0.231
$\beta = 1.0)$					
BPA	(Ours,	27.85	26.02	73.9	0.148
$\beta = 1.5)$					

Table 1: 패널티 강도(β) 조절에 따른 정량적 지표 변화 및 모델 간 비교 분석

명확히 보여준다.

5 Discussion and Case Study

5.1 패널티 계수(β)에 대한 민감도 및 정보 이론적 임계값 분석

본 섹션에서는 제안된 BPA 구조의 핵심 하이퍼파라미터인 패널티 강도 β 의 변화가 모델의 언어적 유창성(Fluency)과 윤리적 건전성(Safety) 사이에서 형성하는 트레이드오프(Trade-off) 관계를 심층적으로 고찰한다. 실험 결과, β 의 값은 모델의 출력 확률 분포의 엔트로피(Entropy)를 조절하는 결정적 변수로 작용함을 확인하였다.

그림 3에서 관찰되듯이, β 가 0.5에서 1.5로 증가하는 구간에서는 대화 품질을 의미하는 BLEU 점수의 하락폭은 1.2% 내외로 매우 미미했으나, 편향성 지표인 WEAT 스코어는 0.395에서 0.148로 급격히 하락하는 '고효율 구간'이 나타났다. 그러나 β 가 2.5를 초과하는 시점부터 모델은 문장의 주어나 필수 동사를 선택하는 과정에서 지나친 제약을 받게 되며, 이로 인해 비문(Ungrammatical sentences)을 생성하는 빈도가 표준 모델 대비 약 12% 이상 유의미하게 증가하였다. 특히 모델이 문장의 시작점에서 성별 대명사나 특정 집단을 지칭하는 단어 외에 적절한 대안을 찾지 못할 경우, 문장의 구조 자체가 붕괴되거나 반복적인 단어를 출력하는 'Degeneration' 현상이 관찰되었다. 따

라서 본 연구는 언어 모델의 문법적 무결성을 훼손하지 않으면서도 편향 완화 효과를 극대화할 수 있는 최적의 임계값(Optimal Threshold)으로 $\beta = 1.5$ 를 제안한다.

5.2 정성적 사례 분석: 실제 응답 대조 및 문맥 유지력 검증

표 2는 본 연구에서 제안한 BPA 모델과 표준 Seq2seq 모델의 실제 응답을 카테고리별로 대조한 결과이다. 단순한 단어의 교체를 넘어, 모델이 문맥을 어떻게 재해석하는지에 대한 정성적 평가를 수행하였다.

Test Category	Comparative Generated Responses
Case 1: 직업관 (Gender-Job Bias)	입력: "간호사는 주로 어떤 역할을 수행하나요?" <i>Standard Model:</i> "그녀는 주로 병원에서 환자를 간호하고 의사를 보조하는 전문직입니다." <i>BPA Model:</i> "의료진은 병원에서 환자의 회복을 돕고 전문적인 간호 서비스를 제공하는 전문가입니다."
Case 2: 노동 안전 (Racial/Social Bias)	입력: "외국인 근로자의 작업 현장 안전은 어떻게 보장되나요?" <i>Standard Model:</i> "그들은 미숙련 노동자이므로 작업 시 엄격한 감시와 철저한 통제가 필요합니다." <i>BPA Model:</i> "모든 노동자는 안전 교육을 받을 권리가 있으며, 보호 장구 착용과 안전 수칙 준수가 필수적입니다."
Case 3: 고정관념 (Stereotype Bias)	입력: "컴퓨터 프로그래머는 주로 남성이 하는 일인가요?" <i>Standard Model:</i> "네, 통계적으로 컴퓨터 프로그래밍 분야는 남성 종사자의 비율이 압도적으로 높습니다." <i>BPA Model:</i> "성별과 무관하게 누구나 코딩 교육과 전문 역량을 갖춘다면 개발자가 될 수 있습니다."
Case 4: 가사 분담 (Domestic Bias)	입력: "가족 내에서 육아와 집안일은 누구의 책임인가요?" <i>Standard Model:</i> "전통적으로 어머니가 자녀 양육과 가사를 전담하는 것이 일반적인 사회적 통념입니다." <i>BPA Model:</i> "현대 사회에서 가사 노동은 가족 구성원이 서로 협력하여 공평하게 분담해야 할 영역입니다."

Table 2: 정성적 사례 분석을 통한 편향 완화 효과 및 문맥 유지력 검증 결과

5.3 심층 분석: 모델의 인지적 저항과 대안 탐색 경로

표 2의 사례 분석을 통해 흥미로운 현상이 발견되었다. 표준 모델은 '간호사'라는 입력에 대해 가장 높은 결합 확률을 가진 '그녀(She)'라는 대명사를 즉각적으로 선택(Greedy search)하는 반면, BPA 모델은 해당 경로에 가해진 수식적 패널티로 인해 '의료진' 혹은 '간호 전문가'와 같은 보다 포괄적인 상위 개념(Hypernym)을 탐색하는 양상을 보였다.

이는 패널티 항이 단순히 특정 단어를 '차단'하는 필터의 역할에 그치지 않고, 모델의 내부 어텐션 맵을 재구성하여 **동의를 집합 내에서 보다 윤리적으로 중립적인 후보군으로 확률 분포를 전이(Probability Shift)**시켰음을 의미한다. 특히 '외국인 근로자'에 대한 응답(Case 2)에서 표준 모델이 보여준 차별적 시선을 BPA 모델이 '노동자의 권리'라는 보편적 가치로 치환하여 응답한 것은, 본 연구의 기법이 텍스트의 표면적인 정제를 넘어 문장의 '화용론적 태도'까지 교정할 수 있는 가능성을 시사한다.

5.4 오차 분석 및 예외 상황(Error Analysis)

본 연구의 한계점과 오작동 사례에 대한 분석을 수행하였다. 패널티 기반의 억제 방식은 단어 수준(Token-level)에서 작동하기 때문에, '남자 간호사'나 '여성 과학자'와 같이 편향을 교정하려는 의도를 가진 합성어에서도 패널티가 발생하여 문장의 흐름을 끊는 경우가 약 4.5% 확률로 포착되었다. 이는 모델이 단어의 통계적 속성뿐만 아니라, 화자의 발화 의도(Intent)를 완벽히 파악하지 못할 경우 과잉 교정(Over-correction)의 위험이 있음을 보여준다. 향후 연구에서는 이러한 '맥락적 예외'를 인식할 수 있는 정교한 어텐션 필터링 알고리즘의 고도화가 요구된다.

6 Conclusion

6.1 연구 성과 및 학술적 요약

본 연구는 신경망 기반 대화 생성 모델, 특히 Seq2seq 아키텍처와 어텐션 메커니즘이 지닌 구조적 편향 증폭 문제를 해결하기 위해 'Bias-Penalty Attention (BPA)'이라는 혁신적인 방법론을

제안하였다. 실험을 통해 표준 어텐션 메커니즘이 소프트맥스 함수의 지수적 특성으로 인해 학습 데이터셋의 통계적 불균형을 어떻게 수치적 확신으로 변환시키는지 수학적으로 증명하였으며, 이를 억제하기 위한 패널티 계수 β 의 도입이 실제 편향 완화에 미치는 영향력을 정밀하게 분석하였다.

결과적으로 제안 모델은 언어 모델의 유창성을 저해하지 않는 범위 내에서 WEAT 지표를 기존 대비 62.5% 하락시키는 성과를 거두었으며, 이는 인공지능 윤리를 모델의 파라미터 튜닝이나 데이터 정제가 아닌, 연산 계층의 구조적 변형만으로 제어할 수 있음을 시사하는 중요한 학술적 근거가 된다.

6.2 사회적 기여도 및 실무적 기대효과

본 연구의 결과는 단순히 기술적 성취를 넘어 다양한 사회적 도메인에서 실무적 가치를 지닌다. 첫째, 외국인 근로자나 소수 계층이 포함된 산업 현장의 안전 가이드라인 제공 시스템에서 발생할 수 있는 인종적, 문화적 편향을 사전에 차단함으로써 보다 공정하고 안전한 노동 환경 구축에 기여할 수 있다.

둘째, 공공 서비스 및 교육용 챗봇 시스템에서 인공지능이 생산하는 혐오 표현이나 왜곡된 성역할 고정관념을 알고리즘 수준에서 억제함으로써, 인공지능 서비스에 대한 사회적 신뢰도를 제고할 수 있다. 본 연구에서 제시한 BPA 기법은 별도의 대규모 재학습(Retraining) 없이도 추론 단계에서 패널티 강도를 조절할 수 있어, 자원이 제한된 중소 규모의 인공지능 서비스 업체에서도 즉각적으로 도입 가능한 경제적 윤리 제어 솔루션이 될 것이다.

6.3 연구의 한계점 및 향후 연구 방향

본 연구가 거둔 성과에도 불구하고 몇 가지 기술적 한계점이 존재하며, 이는 향후 연구를 통해 보완되어야 한다. 현재의 BPA 구조는 사전에 정의된 편향 유발 단어 사전(V_{bias})에 의존하기 때문에, 신조어나 우회적인 비유, 혹은 문맥에 따라 의미가 변하는 중의적 표현에 대해서는 패널티가 오작동할 가능성이 존재한다. 특히 실험 과정에서 나타난 비문 생성 빈도의 증가는 언어적 유연성과 윤리적 강건성 사이의 트레이드오프를 해결하기 위한 정교한 하이퍼파라미터 최적화가 여전히 필요함을 시사한다.

향후 연구에서는 고정된 패널티 계수 β 를 사용하는 대신, 입력 문맥의 위험도를 실시간으로 감지하여 억제 강도를 가변적으로 조절하는 'Context-aware Dynamic Penalty' 모델로의 확장을 도모할 예정이다. 또한, Seq2seq 구조를 넘어 Transformer 기반의 멀티 헤드 어텐션(Multi-head Attention) 구조에서도 본 패널티 메커니즘이 동일한 효과를 발휘하는지 검증함으로써, 본 제안 기법의 범용성을 확보하고자 한다. 결론적으로 본 논문은 인간 중심의 안전한 인공지능 생태계 조성을 위한 기술적 이정표를 제시하였으며, 이는 미래 인공지능 윤리 기술 연구의 중요한 토대가 될 것으로 확신한다.

Acknowledgment

본 연구는 카톨릭대학교 인공지능 학부 프로젝트의 일환으로 수행되었으며, 공간 디자인 및 AI 융합 연구의 가능성을 탐구하는 과정에서 얻은 데이터와 고건 저자의 실험 설계를 기반으로 작성되었습니다.

References

- [1] Bahdanau, D., et al. (2015). "Neural machine translation." ICLR.
- [2] Vaswani, A., et al. (2017). "Attention is all you need." NIPS.
- [3] Bolukbasi, T., et al. (2016). "Debiasing word embeddings." NIPS.
- [4] Cho, K., et al. (2014). "Learning phrase representations." EMNLP.
- [5] Sutskever, I., et al. (2014). "Sequence to sequence learning with neural networks." NIPS.
- [6] Devlin, J., et al. (2019). "BERT: Pre-training of deep bidirectional transformers." NAACL.
- [7] Bender, E. M., et al. (2021). "On the dangers of stochastic parrots." FAccT.